

1. Matriz Estratégica y Comparativa de Costos

Para el desarrollo del flujo de automatización se seleccionaron diferentes herramientas de acuerdo con la función que cumple cada una dentro del proceso. La idea principal es utilizar inteligencia artificial únicamente en las tareas donde realmente aporta valor, evitando hacer uso de modelos más avanzados cuando una tarea sencilla puede resolverse con un modelo más económico.

El flujo está compuesto principalmente por **Notion, OpenAI, Router, Telegram y Gmail**. Notion se utiliza como fuente y almacenamiento de la información, OpenAI se encarga del análisis y clasificación de los casos, el Router permite tomar decisiones según el resultado obtenido y finalmente Telegram o Gmail se utilizan como canales de salida.

Selección del modelo de IA

Para la clasificación y extracción de información se propone utilizar **GPT-4o mini**, ya que la tarea que debe realizar el modelo no requiere un análisis demasiado complejo. Su función principal es interpretar la información recibida, identificar la categoría correspondiente y entregar un resultado que posteriormente será utilizado por el Router.

Por ejemplo, en el flujo planteado, OpenAI puede recibir la información de un caso y determinar si corresponde a una situación **urgente o normal**. A partir de esta clasificación, el Router decide qué camino debe seguir el proceso.

La elección de GPT-4o mini se debe principalmente a tres factores:

- Tiene un costo menor frente a modelos de mayor capacidad.
- Es suficiente para tareas de clasificación, extracción de información y respuestas estructuradas.
- Permite procesar un volumen mayor de solicitudes sin aumentar considerablemente el costo de la automatización.

Un modelo más avanzado, como **GPT-4o**, podría utilizarse como alternativa para casos que requieran mayor contexto o un análisis más detallado. Sin embargo, no sería necesario utilizarlo en cada solicitud, ya que esto aumentaría el costo del flujo sin aportar necesariamente un beneficio proporcional.

Tarea dentro del flujo	Herramienta / modelo	Función	Justificación
------------------------	----------------------	---------	---------------

Detectar nuevos registros	Notion	Identificar la entrada de un nuevo caso	Permite iniciar automáticamente el flujo a partir de la información almacenada.
Buscar información	Notion	Recuperar los datos necesarios para procesar el caso	Permite consultar la información existente antes de enviarla al modelo de IA.
Clasificar y analizar	GPT-4o mini	Clasificar el caso y extraer la información necesaria	Es suficiente para tareas de clasificación y extracción, además de tener un costo reducido.
Guardar el resultado	Notion	Actualizar el registro con la información generada	Permite mantener la trazabilidad del caso durante el proceso.
Tomar una decisión	Router de Make	Determinar qué ruta debe seguir el caso	La decisión puede establecerse mediante reglas, por lo que no requiere otra llamada a IA.
Enviar alerta	Telegram Bot	Enviar una notificación cuando corresponda	Permite comunicar rápidamente los casos que requieren atención.
Enviar respuesta	Gmail	Enviar el correo correspondiente	Se utiliza para los casos que necesitan una comunicación mediante correo electrónico.
Actualizar el registro final	Notion	Guardar el resultado del proceso	Permite conocer qué tratamiento recibió cada caso y mantener el historial.

Comparativa de consumo y costos

Para tener una referencia del costo de la automatización, se puede plantear un escenario de aproximadamente **1.000 mensajes procesados al mes**.

Para realizar una estimación sencilla, se considera un promedio de:

- **300 tokens de entrada por mensaje**
- **100 tokens de salida por mensaje**
- **1 llamada al modelo por cada mensaje**

Esto representaría aproximadamente **300.000 tokens de entrada y 100.000 tokens de salida al mes**.

Tomando como referencia los precios publicados para los modelos, el consumo estimado sería:

Modelo	Tokens de entrada/mes	Tokens de salida/mes	Costo estimado
GPT-4o mini	300.000	100.000	Aproximadamente USD \$0,105
GPT-4o	300.000	100.000	Aproximadamente USD \$1,75

Estos valores son únicamente una **estimación**, ya que el consumo real puede cambiar dependiendo de la cantidad de información enviada al modelo, la extensión de los prompts y la cantidad de texto que genere como respuesta.

Estrategia de ahorro

Una de las principales estrategias para controlar los costos sería utilizar **GPT-4o mini como modelo principal** y reservar los modelos de mayor capacidad para situaciones específicas.

Por ejemplo, si de 1.000 casos mensuales la mayoría corresponde a solicitudes sencillas que pueden clasificarse fácilmente, no tendría sentido procesar todos los casos con un modelo más costoso. En cambio, se podría establecer una regla para que únicamente los casos que presenten mayor complejidad sean enviados a un modelo más avanzado.

También es importante controlar la cantidad de información que se envía a OpenAI. En lugar de enviar todo el contenido almacenado en Notion, el flujo puede seleccionar únicamente los campos necesarios para realizar la clasificación. Esto permite reducir la cantidad de tokens utilizados en cada solicitud.

Otra medida sería solicitar respuestas cortas y estructuradas. Por ejemplo, en lugar de pedirle al modelo una explicación completa, se puede solicitar únicamente una categoría como:

URGENTE

o

NORMAL

Esto reduce el consumo de tokens de salida y facilita posteriormente el trabajo del Router.

Conclusión

La selección de **GPT-4o mini** como modelo principal permite mantener un equilibrio entre costo, velocidad y capacidad de procesamiento. Para el flujo desarrollado, la tarea principal

de la IA es clasificar y extraer información, por lo que no es necesario utilizar un modelo de mayor capacidad en todos los casos.

Además, el resto de la automatización no requiere inteligencia artificial. **Notion** se encarga de almacenar y consultar la información, **Make** controla la lógica del proceso mediante el Router, y **Telegram y Gmail** funcionan como canales de comunicación.

De esta manera, la arquitectura permite automatizar el proceso manteniendo los costos controlados y dejando abierta la posibilidad de incorporar un modelo más avanzado únicamente cuando la complejidad del caso lo justifique.

Nota: Los costos son aproximados y pueden variar según el modelo utilizado, el volumen real de mensajes y la cantidad de tokens procesados.